

Detecção de Spam em Mensagens SMS

Projeto Avaliativo P2 · A.I - Classificadores · UNIMAR 2026/1
Grupo 5 · Domínio: NLP / Segurança · Classificação binária (desbalanceada)

1. Introdução e objetivo

O spam por SMS é um vetor comum de fraudes e phishing, e filtros automáticos são essenciais para proteger os usuários. Este projeto treina e compara classificadores de Machine Learning para distinguir mensagens **legítimas (ham)** de **spam**, a partir apenas do texto, e disponibiliza o melhor modelo em uma aplicação web (Streamlit). Trata-se de um problema de **classificação binária supervisionada com classes desbalanceadas** (~13% de spam).

2. Evolução em relação à P1

Esta versão incorpora as melhorias indicadas na devolutiva e outras adicionais: **(i)** remoção de 403 mensagens duplicadas, eliminando vazamento de dados; **(ii)** uso de *Pipeline* (TF-IDF + classificador), garantindo que a vetorização seja ajustada apenas no treino de cada *fold* da validação cruzada; **(iii)** otimização de hiperparâmetros com *GridSearchCV*; **(iv)** inclusão das curvas *Precision-Recall* e da métrica AUC-PR, mais adequadas a dados desbalanceados; **(v)** análise de limiar de decisão; e **(vi)** salvamento do modelo final com *joblib* para uso no app.

3. Dataset e análise exploratória

Utilizou-se o **SMS Spam Collection (UCI/Kaggle)**, com 5.572 mensagens. Após remover 403 duplicatas exatas, restaram **5.169 mensagens** (4.516 ham e 653 spam, 12,6% spam). A distribuição confirma o forte desbalanceamento, motivando o uso de F1-Score e AUC-PR como métricas principais.




Figura 1 — Distribuição das classes após remoção de duplicatas.

As mensagens de spam são, em média, mais longas (137,9 vs 70,5 caracteres) — um sinal discriminante. As nuvens de palavras mostram vocabulário comercial/golpe no spam (*free, call, txt, claim, win*) e cotidiano no ham (*ok, home, later, got*).



Figura 2 — Palavras mais frequentes por classe (stopwords removidas).

4. Pré-processamento e metodologia

Limpeza: conversão para minúsculas, remoção de pontuação e números e normalização de espaços. **Vetorização:** *TfidfVectorizer* com unigramas e bigramas (*ngram_range=(1,2)*), *sublinear_tf* e remoção de stopwords. **Divisão:** 70% treino, 15% validação e 15% teste, **estratificada** para preservar a proporção de spam. Cada classificador foi encapsulado em um *Pipeline* e teve seus hiperparâmetros otimizados por *GridSearchCV* com *StratifiedKFold* (*k=5*), maximizando o F1. Foram comparados três modelos: **MultinomialNB**, **LogisticRegression** e **LinearSVC** (calibrado).

5. Resultados

A Tabela 1 resume o desempenho no **conjunto de teste** (776 mensagens não vistas no treino).

Modelo	Acurácia	Precisão	Recall	F1-Score	AUC-ROC	AUC-PR
MultinomialNB ★	0,9871	0,9681	0,9286	0,9479	0,9943	0,9780
LinearSVC	0,9871	0,9783	0,9184	0,9474	0,9853	0,9643
LogisticRegression	0,9858	0,9780	0,9082	0,9418	0,9897	0,9699

Tabela 1 — Métricas no conjunto de teste. ★ = modelo final escolhido.

O **MultinomialNB** ($\alpha=0,05$; $\max_features=10000$) foi escolhido por apresentar o melhor **F1-Score (0,9479)** e as maiores AUC-ROC e AUC-PR — coerente com a literatura, que o aponta como baseline forte para detecção de spam. Sua matriz de confusão (Figura 3) revela apenas **3 falsos positivos** (ham bloqueado) e **7 falsos negativos** (spam que passou) entre 776 mensagens.

Matrizes de confusao — conjunto de teste




Figura 3 — Matrizes de confusão dos três modelos (teste).




Figura 4 — Curvas ROC (esq.) e Precision-Recall (dir.). A curva PR é mais informativa em dados desbalanceados.

6. Análise de erros e importância das palavras

A análise de erros mostrou que os **falsos negativos** são spams sem as palavras-gatilho típicas, enquanto os **falsos positivos** são mensagens legítimas que contêm termos também comuns em spam (como *free*). Pelos coeficientes da Regressão Logística (Figura 5), as palavras mais indicativas de spam são *free*, *win*, *prize*, *call*, *claim*, *txt*, *mobile* — confirmando a intuição do domínio.

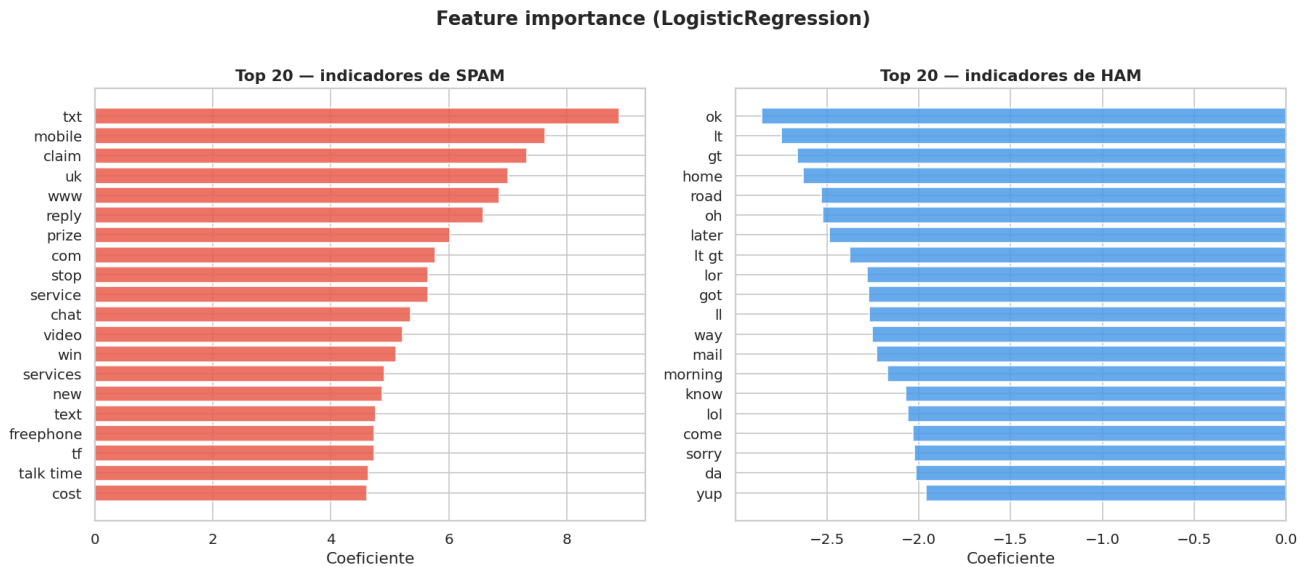


Figura 5 — Palavras mais associadas a spam (vermelho) e ham (azul).

7. Modelo final e aplicação

O *Pipeline* final foi re-treinado com todos os dados rotulados e salvo em **modelo_final.joblib**. A aplicação Streamlit carrega esse arquivo, aplica a mesma limpeza de texto, executa `predict/predict_proba` e exibe a classe (ham/spam) com a probabilidade — permitindo classificar novas mensagens em tempo real.

8. Limitações

O dataset é majoritariamente em inglês e de SMS antigos, o que pode reduzir o desempenho em português ou em mensagens atuais. Por ser um modelo *bag-of-words*, ignora ordem e contexto semântico. Spam sofisticado, sem palavras típicas, ainda pode escapar.

9. Conclusão

Após o tratamento de duplicatas e a otimização de hiperparâmetros, o MultinomialNB alcançou **F1-Score de 0,9479** e **AUC-PR de 0,978** no teste, com pouquíssimos erros. A metodologia baseada em pipelines e validação cruzada estratificada garante resultados honestos e reproduzíveis, e o modelo foi integrado com sucesso a uma aplicação web funcional.